苏州大学实验报告

院、系	计算机学院	姓名	赵鹏	学号	2127405037
课程名称	信息检索综合实践				
指导教师	李正华		实验完成日期		2022/5/9

实验名称： 网页排序

一. 实验目的

1.学习网页排序相关知识。

2.基于向量空间模型对检索出的网页相关性进行排序。

二. 实验内容

1.编写代码改造倒排索引，提前处理出向量空间排序所需的W_{td}、idft、$|d_i|$，并在排序时直接利用该数据进行排序。

2.输入：已分词或未分词的查询语句

3.输出：排序后的查询结果，按如下格式输出到文件：

文件名 1 (余弦相似度 Sim)

句子 1

句子 2

文档名 2

…

三. 解决思路（如流程图或伪代码）、遇到的问题和解决方法、运行结果

解决思路：1.改写作业五代码，重新生成倒排索引。

具体思路为：在以此处理每个文档进行最大匹配分词时，统计文档中的每个词在文档中出现的次数。在计数结束后根据词语在文档中出现次数计算W_{td}和$|d_i|$，将$|d_i|$存储在以文档名为键，以$|d_i|$为值的字典中，在所有文档处理完成后再计算每个词语的idf_t。最后将$|d_i|$以字典的形式输出到索引文件第一行。从第二行开始输出每词语和对应文档及文档对应的W_{td}。

改写后的索引文件格式如下：

{文档 1:|d1|,文档 2：|d2|，文档 3:|d3|…}

词语 1 [idf_t,[文档 1, W_{td}],[文档 2, W_{td}],[文档 3, W_{td}]…]

词语 2 [idf_t,[文档 1, W_{td}],[文档 2, W_{td}],[文档 3, W_{td}]…]

词语 3 [idf_t,[文档 1, W_{td}],[文档 2, W_{td}],[文档 3, W_{td}]…]

第一行为存储的文档$|d_i|$,第二行开始为改写后的倒排索引。

下图为改写后的部分倒排文件：

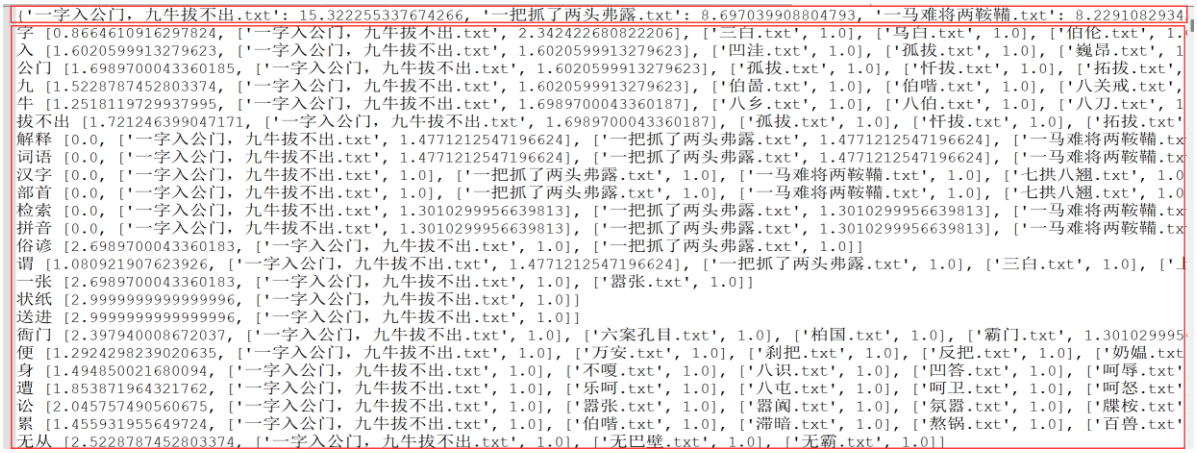

2.读取倒排文件并转换为多种字典。

具体方法为：1.读取第一行转化为文件名->$|d_i|$的字典。

2.读取第二行开始的内容建立词语->idf_t、 [文档名, W_{td}]的字典。

3.建立词语->文件名->列表索引的嵌套字典。在已知词语及文档后快速定位到对应列表的索引，直接获取对应W_{td}，提高检索速度。

3.输入语句，进行查询。

具体方法为：1.利用字符串 split 函数判断是否语句已经完成分词，如果未分词则利用最大匹配分词算法进行分词，并返回分词后的列表。

2.对于每个词语，获取包含该词语的对应文档并加入集合中，作为待排序文档。

3.依次处理每个文档，通过字典快速获取词语列表中每个词在文档中的W_{td}及idf_t，对于未出现的在字典键中的词语进行特殊处理，将对应的W_{td}和idf_t赋值为 0。将结果存储在两个列表中，随后计算余弦值。两个列表中对应位置相乘求和计算 cos 的分子，通过提前建立的字典直接获取$|d_i|$，对每个词语的idf_t平方求和再相加，最后开方并与$|d_i|$相乘作为 cos 的分母。返回分子/分母，最终的结果以[文件名,cos]格式存储在列表中列表中。

4.获取最终结果，根据 cos 值从大到小进行排序。

5.输出结果，依次打开每个文件，遍历文件的每一行、如果一行内包含分词列表中的词，则输出该行。将所有查询结果输出到以查询语句命名的 txt 文件中。

输出格式如下：

文件名 1 (余弦相似度 Sim)
句子 1
句子 2

文档名 2 (余弦相似度 Sim)
句子 1
句子 2

…

教务处制

运行结果：

问题 1：.根据单词在文档中出现的次数计算W_{td}时，如果直接使用 count 函数计数在一些情况下会造成结果偏大的情况。例如：在对“大学里由很多大学生”这句话统计“大学”的出现次数时，使用 count 会把“大学生”里的“大学”也计算为一次。

解决方法：在分词时对每个分词的词语进行计数，在文档分词完毕后统一计算文档中每个词语的W_{td}

问题 2：在建立新的词语->[文件名，W_{td}] 字典后，无法快速获取词语对应的文件名的W_{td}，如果遍历一遍会浪费大量时间。

解决方法：建立一个能够由词语和文件名快速定位到W_{td}的字典，字典中存储列表的索引。

问题 3：在一些特殊情况下(查询词在所有文档里都出现并且不在倒排里)会出现|q|=0 的情况，在这种情况下如果直接计算余弦值会出现除 0 的错误。

解决方法：计算出分子分母后对分母进行一次特判，如果出现分母为 0 则直接返回 0 作为这个文档的 cos 值。

问题 4：经过与同学的计算结果比对，发现在计算W_{td}和idf_t过程中存在浮点数计算误差。

解决方法：由于误差及其微小(例如 2.9999999999996 和 3.0)，可以直接忽略误差。

四. 实验总结

通过本次实验，学习到了网页排序的基本知识及基于向量空间模型的网页排序方法，通过改写倒排、编写代码实现了对给定语句进行分词查询，并根据向量空间模型的 cos 值大小对查询结果进行排序。提升了自己的程序设计能力。